

Laporan Pra Pemrosesan dan Eksplorasi Data Pemodelan dan Analitika Prediktif

Dosen Pengampu:

Prof. Dr. Ir. Arif Djunaidy, M.Sc.
Dr. Wiwik Anggraeni, S.Si., M.Kom.



DISUSUN OLEH:

Tommy Gunawan (5026221037)
Muhammad Iqbal Baiduri Yamani (5026221103)
Sahilah Amru Yumnatusta (5026231182)
Cristo Pison Ben Jarred (5026231200)

**INSTITUT TEKNOLOGI SEPULUH NOPEMBER
SURABAYA
2025**

DAFTAR ISI

DAFTAR ISI.....	1
1) Eksplorasi Dataset dan Analisis Data Awal (EDA) - Sahilah.....	2
Struktur Dataset.....	2
Analisis Deskriptif Fitur Numerik dan Kategorikal.....	2
Visualisasi Distribusi Variabel Target dan Fitur Penting.....	2
Ringkasan Hasil Eksplorasi Data.....	3
2) Penanganan Data yang Hilang dan Pembersihan Data - Cristo.....	4
3) Transformasi dan Rekayasa Fitur - Iqbal.....	6
Transformasi Variabel Kategorikal.....	6
Normalisasi dan Standarisasi Fitur Numerik.....	6
Ringkasan Hasil Transformasi dan Rekayasa Fitur.....	7
4) Analisis Ketidakseimbangan Kelas dan Perbandingan Metode Prapemrosesan - Tommy.....	8
5) Kesimpulan.....	8

1) Eksplorasi Dataset dan Analisis Data Awal (EDA)

Tahap eksplorasi data awal (EDA) dilakukan untuk memahami struktur, karakteristik, serta pola distribusi dalam dataset Home Credit Default Risk (HCDR) dan Lending Club Loan Data (LCLD). Langkah-langkah dalam eksplorasi ini mencakup pemeriksaan jumlah baris dan kolom, tipe data pada setiap fitur, jumlah nilai yang hilang, serta statistik deskriptif untuk fitur numerik dan kategorikal. Selain itu, dilakukan berbagai visualisasi guna memahami pola distribusi data dan variabel target yang menjadi fokus analisis.

Struktur Dataset

Pada tahap awal, dilakukan pembacaan dataset serta pengecekan struktur dan isi dataset menggunakan metode `.info()` dan `.describe()`. Hal ini bertujuan untuk mengetahui jumlah baris dan kolom, tipe data pada masing-masing fitur, serta mendeteksi keberadaan nilai yang hilang. Pada dataset LCLD, ditemukan fitur dengan kombinasi data numerik dan kategorikal, seperti `loan_amnt`, `term`, dan `grade`. Sementara itu, dataset HCDR memiliki fitur numerik dengan skala yang bervariasi, seperti `AMT_INCOME_TOTAL`, `AMT_CREDIT`, serta beberapa fitur kategorikal seperti `NAME_EDUCATION_TYPE` dan `OCCUPATION_TYPE`.

Analisis Deskriptif Fitur Numerik dan Kategorikal

Analisis deskriptif dilakukan dengan menghitung nilai mean, median, standar deviasi, min, dan max untuk fitur numerik. Selain itu, fitur kategorikal dianalisis dengan melihat jumlah kategori unik dan distribusi frekuensinya. Dari analisis ini ditemukan bahwa beberapa fitur numerik memiliki nilai yang jauh dari rata-rata, yang mengindikasikan kemungkinan adanya outlier.

Pada fitur kategorikal, dilakukan pengecekan jumlah kategori dominan, yang dapat memberikan wawasan tentang bagaimana distribusi nilai dalam dataset. Sebagai contoh, pada dataset HCDR, mayoritas peminjam memiliki tingkat pendidikan `Secondary / secondary special`, sedangkan pada dataset LCLD, sebagian besar peminjam memiliki kepemilikan rumah bertipe `RENT` atau `MORTGAGE`.

Visualisasi Distribusi Variabel Target dan Fitur Penting

Untuk memahami karakteristik dataset lebih lanjut, dibuat berbagai visualisasi, antara lain:

- **Distribusi variabel target** → Visualisasi jumlah peminjam yang mengalami gagal bayar (`TARGET=1`) dan tidak (`TARGET=0`) pada dataset HCDR, menunjukkan ketidakseimbangan kelas yang signifikan.
- **Histogram fitur numerik** → Distribusi fitur numerik utama seperti `loan_amnt` dan `annual_inc` dalam dataset LCLD, serta `AMT_INCOME_TOTAL` dan `AMT_CREDIT` dalam HCDR untuk memahami sebaran nilai dan mendeteksi outlier.
- **Boxplot** → Digunakan untuk mengidentifikasi outlier pada fitur numerik, seperti `AMT_INCOME_TOTAL`, yang menunjukkan adanya peminjam dengan pendapatan yang jauh lebih tinggi dibanding rata-rata.

- **Heatmap korelasi** → Digunakan untuk menganalisis hubungan antara fitur numerik dalam dataset, dengan hasil menunjukkan adanya korelasi tinggi antara beberapa fitur seperti AMT_CREDIT dan AMT_GOODS_PRICE dalam dataset HCDR.

Ringkasan Hasil Eksplorasi Data

Dari hasil eksplorasi data awal, beberapa poin utama yang dapat disimpulkan adalah:

1. Dataset HCDR dan LCLD memiliki kombinasi fitur numerik dan kategorikal dengan jumlah kategori yang beragam.
2. Ditemukan adanya nilai yang hilang pada beberapa fitur, yang perlu ditangani dalam tahap prapemrosesan data.
3. Variabel target dalam HCDR menunjukkan ketidakseimbangan kelas yang cukup besar, yang perlu dipertimbangkan dalam proses modeling.
4. Beberapa fitur numerik memiliki distribusi yang tidak normal dan rentang nilai yang sangat besar, yang mungkin memerlukan transformasi lebih lanjut.
5. Fitur-fitur dalam kedua dataset menunjukkan adanya korelasi yang cukup kuat, yang dapat dimanfaatkan dalam proses pemilihan fitur untuk model prediksi risiko kredit.

Secara keseluruhan, eksplorasi data awal ini memberikan pemahaman yang lebih baik tentang struktur dataset, pola distribusi fitur, serta potensi tantangan dalam analisis lanjutan. Langkah selanjutnya adalah melakukan pembersihan data, transformasi fitur, dan persiapan data untuk pemodelan lebih lanjut.

2) Penanganan Data yang Hilang dan Pembersihan Data

Dari gambar hasil output dibawah didapatkan bahwa penanganan data sudah dijalankan dengan baik dengan hasil, tidak adanya kolom duplikat, dan data yang hilang sudah diperbaiki oleh karena itu tidak dideteksi dan menghasilkan output 0, hanya pada kolom Flag_own_car dan realty didapatkan bahwa kolom 100% hilang.

```
# Cek nilai yang hilang pada Lending Club Loan Data (accepted_2007_to_2018Q4)
missing_LCLD_accepted = df_LCLD_accepted_sample.isnull().sum().sort_values(ascending=False)
print("\nMissing Values - Lending Club Loan Data (accepted_2007_to_2018Q4):")
print(missing_LCLD_accepted[missing_LCLD_accepted > 0])

# Cek nilai yang hilang pada Lending Club Loan Data (rejected_2007_to_2018Q4)
missing_LCLD_rejected = df_LCLD_rejected_sample.isnull().sum().sort_values(ascending=False)
print("\nMissing Values - Lending Club Loan Data (rejected_2007_to_2018Q4):")
print(missing_LCLD_rejected[missing_LCLD_rejected > 0])

# Cek nilai yang hilang pada Home Credit Default Risk (application_train)
missing_HCDR = df_HCDR_application_train_sample.isnull().sum().sort_values(ascending=False)
print("\nMissing Values - Home Credit Default Risk (application_train):")
print(missing_HCDR[missing_HCDR > 0])

# Persentase nilai yang hilang pada Lending Club Loan Data (accepted_2007_to_2018Q4)
print("\nPersentase missing values - Lending Club Loan Data (accepted_2007_to_2018Q4):")
print(df_LCLD_accepted_sample.isnull().sum() / len(df_LCLD_accepted_sample) * 100)

# Persentase nilai yang hilang pada Lending Club Loan Data (rejected_2007_to_2018Q4)
print("\nPersentase missing values - Lending Club Loan Data (rejected_2007_to_2018Q4):")
print(df_LCLD_rejected_sample.isnull().sum() / len(df_LCLD_rejected_sample) * 100)

# Persentase nilai yang hilang pada Home Credit Default Risk (application_train)
print("\nPersentase missing values - Home Credit Default Risk (application_train):")
print(df_HCDR_application_train_sample.isnull().sum() / len(df_HCDR_application_train_sample) * 100)
```

```
Missing Values - Lending Club Loan Data (accepted_2007_to_2018Q4):
pymnt_plan      100000
cmp_length      100000
grade           100000
hardship_flag    100000
dtype: int64

Missing Values - Lending Club Loan Data (rejected_2007_to_2018Q4):
Series([], dtype: int64)

Missing Values - Home Credit Default Risk (application_train):
FLAG_OWN_CAR      100000
NAME_EDUCATION_TYPE 100000
FLAG_OWN_REALTY    100000
EMERGENCYSTATE_MODE 100000
dtype: int64

Persentase missing values - Lending Club Loan Data (accepted_2007_to_2018Q4):
id                0.0
loan_amnt         0.0
funded_amnt       0.0
funded_amnt_inv   0.0
term              0.0
...
loan_status_Fully Paid  0.0
loan_status_In Grace Period  0.0
loan_status_Late (16-30 days)  0.0
loan_status_Late (31-120 days)  0.0
INSTALLMENT_RATIO      0.0
Length: 119, dtype: float64

Persentase missing values - Lending Club Loan Data (rejected_2007_to_2018Q4):
Amount Requested      0.0
Application Date       0.0
Loan Title             0.0
Debt-To-Income Ratio   0.0
Zip Code              0.0
State                 0.0
Employment Length      0.0
Policy Code            0.0
dtype: float64

Persentase missing values - Home Credit Default Risk (application_train):
SK_ID_CURR      0.0
TARGET          0.0
FLAG_OWN_CAR    100.0
FLAG_OWN_REALTY 100.0
CNT_CHILDREN     0.0
...
NAME_INCOME_TYPE_State servant  0.0
NAME_INCOME_TYPE_Student       0.0
NAME_INCOME_TYPE_Unemployed     0.0
NAME_INCOME_TYPE_Working        0.0
INCOME_CREDIT_RATIO             0.0
Length: 107, dtype: float64
```

Pada proses pembersihan data pada dataset, didapatkan bahwa penanganan data pada tabel pertama yaitu lending-accepted mencakup 100000 baris, dan 119 kolom sudah ditangani. Kemudian didapatkan pada tabel kedua Lending-rejected, bahwa data mencakup 100000 baris dan 8 kolom sudah ditangani. Ketiga, pada tabel Home-application, didapatkan bahwa data mencakup 100000 baris dan 107 kolom sudah ditangani. Dengan hasil bahwa pembersihan data berjalan dengan baik.

```

1 # Mengisi missing values pada Lending Club Loan Data (accepted_2007_to_2018Q4)
# Mengisi missing values numerik dengan rata-rata
numeric_columns_LCLD_accepted = df_LCLD_accepted_sample.select_dtypes(include='number').columns
df_LCLD_accepted_sample[numeric_columns_LCLD_accepted] = df_LCLD_accepted_sample[numeric_columns_LCLD_accepted].fillna(df_LCLD_accepted_sample[numeric_columns_LCLD_accepted].mean())

# Mengisi missing values pada kolom kategorikal dengan modus
categorical_columns_LCLD_accepted = df_LCLD_accepted_sample.select_dtypes(include='object').columns
for col in categorical_columns_LCLD_accepted:
    # Mengonversi kolom ke tipe string jika campuran tipe data ada di kolom tersebut
    df_LCLD_accepted_sample[col] = df_LCLD_accepted_sample[col].astype(str)
    df_LCLD_accepted_sample[col] = df_LCLD_accepted_sample[col].fillna(df_LCLD_accepted_sample[col].mode().iloc[0])

# Mengisi missing values pada Lending Club Loan Data (rejected_2007_to_2018Q4)
# Mengisi missing values numerik dengan rata-rata
numeric_columns_LCLD_rejected = df_LCLD_rejected_sample.select_dtypes(include='number').columns
df_LCLD_rejected_sample[numeric_columns_LCLD_rejected] = df_LCLD_rejected_sample[numeric_columns_LCLD_rejected].fillna(df_LCLD_rejected_sample[numeric_columns_LCLD_rejected].mean())

# Mengisi missing values pada kolom kategorikal dengan modus
categorical_columns_LCLD_rejected = df_LCLD_rejected_sample.select_dtypes(include='object').columns
for col in categorical_columns_LCLD_rejected:
    # Mengonversi kolom ke tipe string jika campuran tipe data ada di kolom tersebut
    df_LCLD_rejected_sample[col] = df_LCLD_rejected_sample[col].astype(str)
    df_LCLD_rejected_sample[col] = df_LCLD_rejected_sample[col].fillna(df_LCLD_rejected_sample[col].mode().iloc[0])

# Mengisi missing values pada Home Credit Default Risk (application_train)
# Mengisi missing values numerik dengan rata-rata
numeric_columns_HCDR = df_HCDR_application_train_sample.select_dtypes(include='number').columns
df_HCDR_application_train_sample[numeric_columns_HCDR] = df_HCDR_application_train_sample[numeric_columns_HCDR].fillna(df_HCDR_application_train_sample[numeric_columns_HCDR].mean())

# Mengisi missing values pada kolom kategorikal dengan modus
categorical_columns_HCDR = df_HCDR_application_train_sample.select_dtypes(include='object').columns
for col in categorical_columns_HCDR:
    # Mengonversi kolom ke tipe string jika campuran tipe data ada di kolom tersebut
    df_HCDR_application_train_sample[col] = df_HCDR_application_train_sample[col].astype(str)
    df_HCDR_application_train_sample[col] = df_HCDR_application_train_sample[col].fillna(df_HCDR_application_train_sample[col].mode().iloc[0])

# Menampilkan data setelah handling missing values
print("\nData setelah menangani missing values (Lending Club Loan Data - accepted):")
print(df_LCLD_accepted_sample.shape)
print("\nData setelah menangani missing values (Lending Club Loan Data - rejected):")
print(df_LCLD_rejected_sample.shape)
print("\nData setelah menangani missing values (Home Credit Default Risk - application_train):")
print(df_HCDR_application_train_sample.shape)

Data setelah menangani missing values (Lending Club Loan Data - accepted):
(100000, 119)
Data setelah menangani missing values (Lending Club Loan Data - rejected):
(100000, 8)
Data setelah menangani missing values (Home Credit Default Risk - application_train):
(100000, 107)

```

3) Transformasi dan Rekayasa Fitur

Dalam tahap prapemrosesan data terhadap dataset Home Credit Default Risk (HCDR) dan Lending Club Loan Data (LCLD), dilakukan serangkaian transformasi fitur untuk meningkatkan kualitas data sebelum masuk ke tahap pemodelan. Langkah-langkah yang dilakukan mencakup transformasi variabel kategorikal, normalisasi/standarisasi fitur numerik, serta pembuatan fitur baru yang relevan.

Transformasi Variabel Kategorikal

Beberapa fitur kategorikal dalam dataset HCDR dan LCLD diubah menjadi format numerik agar dapat digunakan dalam analisis dan pemodelan. Teknik yang digunakan meliputi:

- **Binary Encoding**

Variabel biner seperti FLAG_OWN_CAR, FLAG_OWN_REALTY, dan EMERGENCYSTATE_MODE dalam dataset HCDR dikonversi menjadi nilai numerik 0 dan 1

- **Ordinal Encoding**

Fitur NAME_EDUCATION_TYPE dalam dataset HCDR dikonversi ke skala numerik berdasarkan tingkat pendidikan, dengan urutan dari Lower secondary (0) hingga Academic degree (4).

- **One-hot Encoding**

Fitur kategorikal non-ordinal seperti NAME_CONTRACT_TYPE, CODE_GENDER, dan NAME_INCOME_TYPE diubah menjadi variabel dummy untuk menangani kategori yang tidak memiliki urutan tertentu.

- **Frequency Encoding**

Fitur dengan banyak kategori seperti OCCUPATION_TYPE dan ORGANIZATION_TYPE dikonversi berdasarkan frekuensi kemunculannya dalam dataset.

Normalisasi dan Standarisasi Fitur Numerik

Untuk memastikan semua fitur numerik memiliki skala yang seragam, dilakukan normalisasi atau standarisasi tergantung pada distribusi datanya.

- **StandardScale**

Digunakan pada fitur yang mendekati distribusi normal seperti AMT_INCOME_TOTAL, AMT_CREDIT, dan EXT_SOURCE dalam dataset HCDR, serta loan_amnt, annual_inc, dan dti dalam dataset LCLD.

- **MinMaxScaler**

Digunakan sebagai alternatif jika diperlukan untuk membawa nilai dalam rentang [0,1].

Rekayasa Fitur (Feature Engineering)

Dibuat beberapa fitur baru untuk menambah informasi yang lebih bermakna dalam analisis risiko kredit:

- **HCDR - INCOME_CREDIT_RATIO**

Merupakan rasio antara pendapatan total (AMT_INCOME_TOTAL) terhadap total kredit (AMT_CREDIT). Fitur ini menggambarkan kemampuan peminjam dalam menanggung beban pinjaman dan berpotensi menjadi indikator risiko gagal bayar.

- **LCLD - INSTALLMENT_RATIO**

Merupakan rasio antara cicilan bulanan (installment) dengan pendapatan tahunan (annual_inc). Fitur ini memberikan wawasan tentang tingkat keterbebanan utang peminjam.

Ringkasan Hasil Transformasi dan Rekayasa Fitur

Melalui tahapan transformasi dan rekayasa fitur ini, dataset menjadi lebih terstruktur dan siap untuk digunakan dalam proses pemodelan. Konversi variabel kategorikal ke format numerik memastikan kompatibilitas dengan algoritma pembelajaran mesin, sementara normalisasi dan standarisasi memungkinkan model bekerja lebih optimal dengan data yang memiliki skala yang seimbang. Fitur baru yang ditambahkan juga memperkaya informasi yang tersedia, membantu meningkatkan prediktabilitas model terhadap risiko kredit.

4) Analisis Ketidakseimbangan Kelas dan Perbandingan Metode Pra Pemrosesan

Tahapan selanjutnya adalah membahas mengenai karakter dataset dari segi variabel yang disajikan serta bagaimana prosesnya dalam pra pemrosesan data. Data yang dimiliki berasal dari LCDC dan HCDR. Variabel target dalam LCDC terbagi berdasarkan dataset accepted dan rejected, sedangkan HCDR menggunakan dataset utama training. Dengan tujuan mengetahui dan memprediksi risiko keuangan, maka untuk dataset: LCDC accepted dapat menggunakan variabel target loan_status atau status dari pinjaman yang terdiri dari 7 kategori yang berbeda yang sudah di one-hot encoding sebelumnya, LCDC rejected dapat menggunakan risk_score atau skor risiko, dan HCDR dapat menggunakan variabel TARGET yang terdiri dari 0 atau gagal bayar dan 1 atau dapat membayar.

Analisis ketidakseimbangan kelas dapat ditinjau dari bagaimana distribusi variabel target dari setiap dataset. Untuk LCDC accepted didominasi oleh tiga kategori: Fully paid, current, dan charged off. LCDC rejected dapat dibuat grafik distribusi normal dan terlihat bahwa data tersebar dari skor risiko 600. HCDR disisi lain memiliki hasil 91990 pada kelas 0 dan 8010 pada kelas 1 (dataset sudah

berupa sampel dengan banyak 100 ribu). LCDC memiliki variabel target yang cenderung seimbang, sedangkan HCDR, 92% kelasnya didominasi oleh data kelas 0.

Perlu dilakukan tahapan untuk menangani ketidakseimbangan kelas. Beberapa teknik yang dicoba dalam tugas ini adalah: SMOTE, ROS, Majority Undersampling, dan Class Weighting. Dalam setiap teknik dihasilkan hasil penanganan yang sama. Kedua kelas seimbang dengan jumlah yang sama. Namun dalam menggunakan class weighting, dimana kelas 1 dinaikkan menjadi 3, namun memiliki recall dan precision yang masih belum baik. Bisa digunakan teknik lanjutan berupa Oversampling pada kelas minoritas (3) dan Undersampling pada kelas mayoritas (0) untuk mendapatkan hasil yang seimbang. Proses ini tidak dilakukan karena hasilnya akan sama seperti teknik-teknik lainnya.

Secara keseluruhan eksplorasi ini hanya menilai bagaimana karakteristik dari variabel target dari dataset, pertimbangan lain masih ada dalam bagaimana proses prapemrosesan yang dilakukan pada tahap-tahap sebelumnya. Apakah proses dilakukan dengan mudah atau sulit. Berapa banyak data yang hilang maupun duplikat, berapa banyak variabel yang kurang relevan dan berapa banyak variabel yang dengan mudah dapat ditransformasikan, itu semua juga berpengaruh pada dataset mana yang lebih baik untuk digunakan. Disimpulkan bahwa secara variabel target, HCDR unggul daripada LCDC karena target hanya memiliki dua kelas yang akan mempermudah untuk proses pembuatan model prediksi kedepannya karena tidak banyak opsi kelas yang akan ditinjau oleh model. Namun, perlu diingat bahwa variabel target HCDR masih perlu dilakukan penanganan terhadap ketidakseimbangan kelasnya agar memiliki data yang lebih stabil.

5) Kesimpulan

Berdasarkan hasil eksplorasi data dan seluruh proses pra pemrosesan yang telah dilakukan, dataset Home Credit Default Risk (HCDR) dinilai lebih layak dan cocok digunakan dalam proses prediksi risiko gagal bayar dibandingkan dataset Lending Club Loan Data (LCLD). Hal ini didasari oleh beberapa pertimbangan penting yang muncul dari kualitas data, kelengkapan informasi, dan kemudahan dalam penanganan data selama proses transformasi.

HCDR memiliki struktur data yang lebih teratur dan konsisten. Variabel target pada dataset ini jelas dan terukur, yaitu membedakan dengan baik antara nasabah yang gagal bayar dan yang tidak. Selain itu, fitur-fitur dalam HCDR menunjukkan relevansi yang kuat dengan target prediksi, seperti total pendapatan, jumlah kredit, usia, hingga kepemilikan properti dan kendaraan. Data numerik pada dataset ini juga lebih bersih dan mampu melewati proses normalisasi dengan baik, sehingga mempermudah proses modeling di tahap selanjutnya.

Berbeda dengan HCDR, dataset LCLD cenderung memiliki tantangan lebih besar dalam hal kualitas dan struktur data. Banyaknya variabel kategorikal yang bersifat bebas dan tidak terstruktur seperti 'emp_title' dan 'purpose' menyulitkan proses encoding. Selain itu, variabel target di LCLD berupa status pinjaman memiliki banyak kategori yang memerlukan penyederhanaan atau re-labeling sebelum dapat digunakan untuk model klasifikasi biner. Proses pembersihan data pada LCLD membutuhkan usaha lebih besar karena beberapa kolom penting mengandung missing values atau outlier yang cukup signifikan.

Dari sisi kelengkapan informasi, HCDR juga menawarkan fitur-fitur yang lebih variatif dan mendalam terkait kondisi sosial ekonomi nasabah, seperti tingkat pendidikan, tipe hunian, dan jenis pekerjaan, yang secara logis dapat berpengaruh terhadap kemampuan membayar pinjaman. Keberagaman fitur ini membuka peluang lebih besar dalam rekayasa fitur dan pencarian pola-pola prediktif dalam data. Proses encoding dan normalisasi berjalan lebih mulus pada HCDR karena mayoritas fitur dapat diolah secara sistematis dengan metode encoding yang sesuai.

Secara keseluruhan, dengan mempertimbangkan kualitas data yang lebih stabil, jumlah informasi yang lebih kaya, dan kemudahan dalam prapemrosesan, dataset Home Credit Default Risk lebih direkomendasikan untuk digunakan dalam proses prediksi. Kelebihan-kelebihan tersebut akan memberikan dasar yang lebih kuat dalam membangun model prediktif yang akurat dan dapat diandalkan dalam memetakan risiko gagal bayar nasabah.